

國立臺北大學資訊工程學系

Department of Computer Science & Information Engineering

National Taipei University

碩士論文

Master Thesis

指導教授：陳裕賢 博士

Advisor : Dr. Yuh-Shyan Chen

低軌道多波束衛星網路之節能型換手決策：基於角度感知多
鯰魚式多目標強化學習

Energy-Efficient Handover Decision for LEO Multi-Beam
Satellite Networks Based on Angle-Aware Multi-Catfish
MODQN

研究生：吳柏宏

Student : Bo-Hung, Wu

中華民國 115 年 7 月

July, 2026

摘要

低軌衛星（LEO）網路覆蓋廣、延遲較低，但衛星高速移動使波束覆蓋快速變化，換手因而頻繁且不易決策。既有的多目標深度 Q 學習網路（Multi-Objective Deep Q-Learning Network, MODQN）以吞吐量、換手成本與負載平衡三個獎勵項建模此問題，但吞吐量獎勵未反映偏軸角與干擾對能量效率的影響。每位使用者又各自取最大值、看不到彼此的選擇，容易一起指向同一波束而過度集中；同一波束上的使用者均分頻寬，集中會直接壓低每個人的速率，而學習端從訓練到部署都看不到其他使用者當步的選擇。以該方法為基準，擴充為鯰魚多目標強化式學習（Multi-Catfish Reinforcement Learning, MCRL）框架。獎勵端把吞吐量改為角度感知能量效率，並由鏈路角度增益直接決定發射功率：每一段 uninterrupted served physical link 以固定的段起始功率 p^0 起始，只有連續同一實體鏈路時才依前一步功率與角度增益比遞推。偏軸角降低波束增益時，同一連續服務段的遞推功率可能上升，並與實際 SINR、吞吐量及系統耗能共同改變能量效率；handover、outage、unserved、re-entry 與 episode reset 都重新起始。訓練時，主代理與鯰魚代理各是一組三目標 MODQN：兩端的三個 Q 網路均與能量效率、換手及負載平衡一一對應，鯰魚代理三網路則共用一條環境軌跡與一個經驗池。經驗塑形採能效分層、非對稱折扣與週期性混合批次介入，獎勵塑形只在鯰魚代理能效獎勵加入配對競爭項，兩者都只在訓練期作用，部署選法不變。

關鍵字：低軌衛星、多波束網路、換手決策、多目標強化式學習、MODQN、Multi-Catfish、負載平衡、能量效率

1. Introduction

近年來行動通訊朝第六代行動通訊與非地面網路發展。低軌衛星能提供大範圍覆蓋與較低傳播延遲，可服務偏遠地區、海上與空中等難以部署地面基礎建設的環境，因而受到重視。但低軌衛星高速繞行地球，使用者可連接的衛星與波束隨時間不斷改變，連線維持與換手決策也因此更加困難。

在多波束低軌衛星系統中，一顆衛星以多個波束服務不同地理區域，使用者可能因衛星移動、波束覆蓋邊界改變或服務品質下降，而需在不同波束或不同衛星間換手。若只依訊號強度選波束，可能造成部分波束負載過高；只追求減少換手，可能讓使用者停留在逐漸變差的連線；只顧負載平衡，又可能犧牲部分使用者的傳輸品質。因此，低軌衛星的多波束換手不宜只用單一指標，而需同時考慮吞吐量、換手成本與負載平衡等多個目標。

為了處理這類動態決策問題，既有研究已從深度強化式學習與多目標學習等方向處理低軌衛星換手問題，分別關注接取延遲與碰撞，以及吞吐量與換手成本等面向 [1], [2]。其中，Sun 等人提出的多目標深度 Q 學習網路（Multi-Objective Deep Q-Learning Network, MODQN）將低軌衛星多波束換手表達為多目標深度強化式學習問題 [2]。

另一方面，能源感知、波束增益與頻譜共存相關研究顯示，鏈路幾何、功率成本與干擾都會影響換手及能源評估 [3], [4], [5]；動態傳播條件下的換手研究強調通道狀態與負載 [6]，隨機流量和時變拓撲下的波束管理則凸顯服務品質、負載與系統資源之間的取捨 [7]。然而，前述研究多從個別面向處理問題，尚缺少一個將偏軸角、由角度增益直接決定的發射功率，以及 MODQN 多目標訓練整合於低軌衛星多波束換手的框架。

因此，本文以 MODQN 為基準，擴充為鯰魚多目標強化式學習（Multi-Catfish Reinforcement Learning, MCRL），並針對能量效率與波束集中問題調整獎勵與訓練方式。主要貢獻如下：

- MCRL 保留 MODQN 的多目標強化式學習架構，把第一個獎勵項由吞吐量改為角度感知能量效率。每個 uninterrupted served physical-link segment 以段起始功率 p^0 起始，連續同一實體鏈路時由前一步功率與角度增益比遞推；同一個實際功率再決定干擾、吞吐量與系統耗能，公式不加 cap、clip 或 projection。
- MCRL 保留部署時逐使用者取最大值的選擇規則。訓練端加入經驗塑形與獎勵塑形，兩者只在訓練期間作用。部署時的輸入表示與選法都與 MODQN 相同。

其餘章節安排如下。第二章回顧低軌衛星換手、多波束資源管理、能量效率與強化式學習的相關研究。第三章說明系統模型與問題形式化。第四章介紹 MCRL 方法。第五章說明模擬設定與評估方式。第六章總結研究內容，並說明研究限制與未來可能方向。

2. Background

本章先回顧低軌衛星換手、多目標強化式學習、鯰魚競爭學習與容量受限決策，再說明本研究的問題定位。

2.1 Related Work

低軌衛星換手問題涉及衛星高速移動、波束覆蓋變化、使用者連線品質與系統負載等因素。既有研究首先將深度強化式學習用於換手決策。Lee 等人 [1] 以深度強化式學習學習換

手協定，以降低接取延遲與碰撞情形。這類方法透過與環境互動學習決策，較能因應隨時間變化的通訊環境。

隨著能源成本受到重視，換手決策也開始納入能量考量。Ntabeni 等人 [3] 提出能量感知 Q 學習，把訊號品質、換手次數與能量效率一併納入。Chen 等人 [4] 提出聯合低軌衛星換手與快速波束切換 (HOBS) 演算法，利用歷史訊號品質與波束索引縮小搜尋範圍，以降低波束訓練延遲；該方法同時考量訊號干擾雜訊比、波束發射功率、波束增益與波束切換，並把同衛星與跨衛星干擾納入訊號品質計算。Mendonça 等人 [5] 在頻譜共存的換手情境中考量偏軸天線損失與干擾管理，說明波束角度與干擾對換手決策具有影響。Liu 等人 [6] 則以多代理深度強化式學習處理換手，以三態 Markov 模型描述動態傳播條件，使決策能同時考慮通道狀態、負載與換手表現。第三章的通道、干擾與功率模型參考了上述研究對訊號品質與波束功率的處理方式。

多目標強化式學習著重於換手決策中的多項取捨。Sun 等人 [2] 建立的 MODQN 把低軌衛星的多波束換手設計為多目標深度強化式學習問題，以吞吐量、換手成本與負載平衡為三個獎勵項，並用三個並行的 Q 網路各自學習一個目標的動作價值。由於同樣關注低軌衛星的多波束換手、且需同時處理多個目標，MODQN 是本方法最主要的基準。Song 等人 [8] 也以深度強化式學習將吞吐量、換手次數與負載平衡納入多目標換手。Tajmaje [9] 以決策值進行模組化純量化；Basaklar 等人 [10] 則讓不同目標在學習過程中分別處理，而非在一開始合成單一純量。MCRL 沿用 MODQN 的三個目標網路與線性純量化，改動集中在第一個獎勵的定義與訓練方式。

本研究採用的 MODQN 基準骨幹如圖 2-1。三個 Q 網路分別估計能量效率、換手與負載平衡的動作價值，再以權重 Ω 純量化並透過 ϵ -greedy 選擇動作。環境回傳三維獎勵與下一狀態，轉移存入回放池後，以目標網路建立時間差分目標並更新三個線上網路。圖中第一個目標採用本研究的角度感知能量效率；MCRL 額外的訓練機制於第四章說明。




Fig. 2-1 MODQN baseline used in this study

圖 2-1：本研究使用的 MODQN 基準骨幹。三個目標 Q 網路共用狀態與可行動作遮罩，經權重 Ω 純量化後選擇動作；環境轉移進入回放池，三個線上／目標網路分別以其目標獎勵更新。第一個目標顯示本研究採用的角度感知能量效率，與原始 MODQN 的吞吐量目標不同；圖中不含 MCRL 額外的訓練期塑形。

訓練經驗的選取與使用也會影響學到的策略。Schaul 等人 [11] 提出的優先經驗回放依時間差分誤差調整取樣機率，讓資訊量較高的轉移更常被使用。Ke [12] 提出的鯰魚效應深度強化式學習（CDRL）則在主代理旁加入鯰魚角色，於訓練中促進探索與經驗利用，而不直接輸出部署決策。CDRL 原本用於 RIS 輔助通訊的節能控制；本研究將此輔助訓練方式延伸到多目標換手，使主代理與鯰魚代理都採三目標 MODQN，每個代理內的三個網路分別對應三個目標。一般按網路實體建模的多代理強化式學習，會依問題設定把使用者、衛星或波束當作代理單位，讓多個代理共同決策。MCRL 的兩個代理則是同一換手問題中的訓練

角色，不分別控制某個使用者、衛星或波束。鯰魚代理在訓練期間提供額外經驗與競爭訊號主代理仍根據自己的經驗更新。第四章將說明這些訓練機制。

容量與資源限制也是多波束系統的重要問題。Zhu 等人 [7] 在隨機流量到達與時變拓樸的條件下探討多波束低軌衛星網路的波束管理，嘗試在服務品質、波束負載與系統資源之間取得平衡。在以強化式學習處理約束方面，Calvo-Fullana 等人 [13] 將約束資訊加入狀態，Agorio 等人 [14] 也將此作法用於多代理指派問題。Holder 等人 [15] 以強化式學習處理有限資源下的衛星指派，Ye 等人 [16] 則在蜂巢式網路中研究兼顧負載平衡的使用者關聯。第四章的訓練塑形策略以這些約束處理方法為參考。

2.2 Motivation

綜合第 2.1 節，本研究聚焦三個尚未被同時處理的問題。第一，既有多目標換手方法的第一個獎勵往往仍以吞吐量為主；能量感知研究則較少把鏈路角度增益、偏軸角造成的功率變化、干擾、實際吞吐量與系統能耗串成同一條能效計算鏈。第二，MODQN 的三個目標通常採用相同的學習流程，而既有鯰魚式輔助學習多設定在單一目標問題，尚未定義如何讓輔助訓練按不同目標分工。第三，每位使用者獨立選擇時，無法直接看見同一時間步其他使用者的選擇與各波束的壅塞程度；既有約束處理常改變部署時的指派程序，或將約束資訊加入狀態，較少在保留原本部署選法的前提下處理這個問題。

本研究以兩類設計回應上述問題。第一，將第一個獎勵改為角度感知系統能量效率的逐使用者可加貢獻，讓偏軸角造成的鏈路品質與功率代價進入同一個目標。第二，在 Multi-Catfish 訓練中，主代理與鯰魚代理都採三目標 MODQN，兩組各自的三個 Q 網路分別對應能量效率、換手與負載平衡。訓練過程包含經驗塑形與獎勵塑形：經驗塑形透過能效分層、非對稱折扣與週期性混合批次介入改變訓練時取用的經驗；獎勵塑形只在鯰魚代理的第一個目標加入同狀態的競爭比較，使輔助訓練有明確的目標對應。兩個塑形策略只在訓練期作用部署時只保留主代理，每位使用者仍各自取最大值。

偏軸角增大時，波束增益降低，接收訊號與 SINR 可能下降，因而降低吞吐量；在同一連續服務段，前一步增益較高而目前增益降低時，previous-step recurrence 可能提高目前 RF power，並改變功率放大器耗能。新 segment 不沿用 inactive link 的功率，而是重新從 p^0 開始；recurrence 不含 power cap、clip 或 projection。完整模型於第 3.1.3 節說明，正式獎勵於第 3.2 節定義。

3. Preliminaries

本章先說明使用者如何從可見波束中選擇服務波束，再介紹這條連線的訊號品質、吞吐量與耗能。最後將這些量整理成能量效率、換手成本與負載平衡三個目標。

3.1 System Model

3.1.1 Network Model

考慮一個多波束低軌衛星下行通訊系統。低軌衛星持續移動，因此使用者可見的衛星與波束會隨時間改變。將時間離散為依序排列、長度為 Δt 的時間步，系統在每一步為每位使用者選擇一個可用的服務波束； Δt 的設定列於第 5.1 節。整體場景如圖 3-1 所示。




Fig. 3-1 LEO multi-beam satellite system model

圖 3-1：多波束低軌衛星網路的系統模型。每位使用者從可見衛星提供的候選波束中選擇服務波束。波束方向會影響訊號品質，多位使用者選到相同波束時會共同使用其資源；系統也必須考慮波束干擾與換手成本；沒有使用者選取的波束不會啟用。

Users, Satellites, and Beams

以 $U=\{1,\dots,U\}$ 、 $S=\{1,\dots,S\}$ 與 $V=\{1,\dots,V\}$ 分別表示使用者、衛星與波束索引集合； u 、 s 、 v 與 t 則表示使用者、衛星、波束與時間步索引。

令 $x_{u,s,v}(t)$ 表示實際連線結果。當 $x_{u,s,v}(t)=1$ 時，使用者 u 由衛星 s 的波束 v 服務；否則為 0。每位使用者最多連上一個波束，因此

$$x_{u,s,v}(t) \in \{0,1\}, \sum_{s \in S} \sum_{v \in V} x_{u,s,v}(t) \leq 1. \quad (3.1)$$

以 $z_{s,v}(t)$ 表示波束 (s,v) 是否啟用。對任意 $u \in U$ 、 $s \in S$ 與 $v \in V$ ，使用者只能連到已啟用的波束，因此

$$z_{s,v}(t) \in \{0,1\}, x_{u,s,v}(t) \leq z_{s,v}(t). \quad (3.2)$$

Beam Activation and Load

波束 (s,v) 實際服務的使用者數量為

$$U_{s,v}(t) = \sum_{u \in U} x_{u,s,v}(t). \quad (3.3)$$

本研究只啟用有使用者連接的波束，波束的啟用狀態因此由連線結果直接決定：

$$z_{s,v}(t) = \begin{cases} 1, & U_{s,v}(t) > 0, \forall s \in S, v \in V. \\ 0, & U_{s,v}(t) = 0, \end{cases} \quad (3.4)$$

沒有使用者的波束不發射功率，也不產生干擾。本研究不另設每顆衛星可同時啟用的波束數上限。

3.1.2 Geometry and Channel Model

在低軌衛星通訊中，幾何關係同時決定使用者與衛星的距離，以及使用者相對於波束中心的方向。參考非地面網路通道模型與低軌衛星相關研究 [17], [18]，定義使用者 u 與衛星 s 之間的斜距如式 (3.5)：

$$d_{u,s,v}(t) = \sqrt{R_E^2 \sin^2 \alpha_{u,s}(t) + h_s^2 + 2 R_E h_s - R_E \sin \alpha_{u,s}(t)}. \quad (3.5)$$

其中 $\alpha_{u,s}(t)$ 為使用者相對於衛星的仰角， R_E 為地球半徑， h_s 為衛星高度。 v 將斜距記為候選波束鏈路層量；對同一顆衛星的不同波束，它的數值可以相同。斜距是後續線性鏈路功率因子的一部分，該因子不直接承載 wanted-link 的角度型樣。

偏軸角描述使用者方向與波束中心方向之間的角度差。多波束低軌衛星模型以兩個方向向量的夾角定義偏軸角 [19, Eq. (5)]，因此使用者 u 相對於波束 (s,v) 的偏軸角定義如式 (3.6)：

$$\theta_{u,s,v}(t) = \arccos \left(\frac{v_{u,s,v}(t) \cdot r_{u,s,v}(t)}{\|v_{u,s,v}(t)\| \|r_{u,s,v}(t)\|} \right). \quad (3.6)$$

其中， $v_{u,s,v}(t)$ 表示候選鏈路 (u,s,v) 的波束中心方向向量， $r_{u,s,v}(t)$ 表示同一候選鏈路由衛星指向使用者的方向向量。兩者以三下標標示資料所有權；同一波束的 v 可在不同使用者間取相同值，同一使用者與衛星的 r 也可在不同波束間取相同值。偏軸角是本文把幾何資訊導入能量效率的入口。

沿用多波束衛星常用、亦見於 HOBS 的角度型樣 [4], [20]，發射端增益只保留其對偏軸角的依賴：

$$G^T(\theta, \theta_3), G^T(0, \theta_3) = G_0. \quad (3.7)$$

其中 G_0 為波束中心增益， θ_3 表示全 3 dB 半功率波束寬；因此其單邊半功率角為 $\theta_3/2$ 。為了讓正文的可調天線參數與模擬器一一對應，採用一層 normalized pattern 展開：

$$G^T(\theta, \theta_3) = G_0 F(\theta, \theta_3), G^T(0, \theta_3) = G_0, F(0, \theta_3) = 1. \quad (3.8)$$

角度型樣採用 HOBS 式 (3) [4] 的 J_1/J_3 型樣，角度參數與 pattern 為

$$\mu(\theta, \theta_3) = 2.07123 \frac{\sin \theta}{\sin(\theta_3/2)}, F(\theta, \theta_3) = \left[\frac{J_1(\mu(\theta, \theta_3))}{2\mu(\theta, \theta_3)} + \frac{36 J_3(\mu(\theta, \theta_3))}{[\mu(\theta, \theta_3)]^3} \right]^2. \quad (3.9)$$

其中 $J_1(\cdot)$ 與 $J_3(\cdot)$ 分別為第一類貝索函數的一階與三階，2.07123 是該式的固定角度參數，同一數值亦見於其他多波束衛星文獻； F 在 $\theta=0$ 自然等於 1 ($1/4+3/4$)，因此不需要額外的 boresight 正規化常數；但 $J_1(\mu)/(2\mu)$ 與 $36 J_3(\mu)/\mu^3$ 在 $\mu=0$ 是 $0/0$ ，數值上以 $\mu \propto \epsilon_\mu$ 時直接取該極限值處理， ϵ_μ 的設定列於第 5.1 節。 θ_3 雖是固定的天線參數，但它出現在 μ 定義式的右側，並經由 μ 決定 F 與 G^T 的形狀，因此列為三者的引數：每一條定義式的等號左側都必須涵蓋右側出現的量。 G_0 不同，它只是乘性的尺度常數，不改變型樣形狀，故不列入引數。式 (3.10) 之後的公式在特定鏈路的偏軸角上套用同一個函數，並明寫固定參數為 $G^T(\theta_{u,s,v}, \theta_3)$ 。這一層不引入帶三下標的增益變數，也不設型樣選擇器。

本研究不沿用 HOBS [4] Table I 的 $G_0=40$ dBi。該表列出的孔徑 $10c/f_c$ 、增益 40 dBi 與波束寬三值互斥；在量綱合法的兩種讀法下，40 dBi 分別要求孔徑效率 $\eta=2.53$ （半徑讀法）或 $\eta=10.13$ （直徑讀法），均大於 1。本研究改由波束寬一致的孔徑重導： $D=1.0275\lambda/\theta_3=17.7\lambda$ ；取 3GPP TR 38.821 [22] 各列反推的 Ka 頻段孔徑效率 0.639 – 0.645，得 $G_0=2000$ (33.0 dBi)。數值列於第 5.1 節。本研究的 θ_3 一律指全半功率波束寬，與第

5.1 節的格半徑 $R_b = h_s \tan(\theta_3/2)$ 一致；HOBS 式 (3) 以單邊半功率角為分母，故式 (3.9) 代入 $\theta_3/2$ 。常數 2.07123 正校準於此點： $\mu=2.07123$ 時 $F=1/2$ 。

令 $H_{u,s,v}(t)$ 表示不直接承載 wanted-link 角度型樣的線性鏈路功率因子。為了與通道實作對應，H 展開為

$$H_{u,s,v}(t) = 10^{-\frac{L_{u,s,v}(t)}{10}} G_{u,s,v}^R(t), \quad (3.10a)$$

其中

$$L_{u,s,v}(t) = L_f(d_{u,s,v}(t), f_c) + L_g(\alpha_{u,s}(t)) + L_c(\alpha_{u,s}(t)) + L_s(\alpha_{u,s}(t)). \quad (3.10b)$$

四項損耗沿用 HOBS 式 (1) 的四類損耗，本文以單字母下標記為 $L = L_f + L_g + L_c + L_s$ ： L_f 為自由空間路徑損耗、 L_g 為大氣氣體吸收、 L_c 為閃爍、 L_s 為遮蔽衰落，後三項皆隨仰角變化，其模型與數值列於第 5.1 節；四項皆以 dB 表示，代入 H 前轉成線性尺度； $G_{u,s,v}^R(t)$ 是接收端線性增益。公開展開不再往下加項；掃描損耗、NLoS clutter 等實作層通道修正併入 $H_{u,s,v}(t)$ ，不取得公開符號，也不是可調參數。

$G_{u,s,v}^R(t)$ 以軸心增益扣除離軸損耗表示。令 $\theta_{u,s}^R(t)$ 為使用者接收天線指向與第 s 顆衛星方向之間的夾角（以度為單位），則

A_R 、 B_R 與下限 G_-^R 取自 ITU-R S.465-6 的地球站參考輻射型樣 [21]，其適用範圍為 2 至 31 GHz，涵蓋本文的 f_c 。三者並非各自獨立設定：該建議書以 $A_R - B_R \log_{10} \theta^R$ 描述 $\theta_-^R \leq \theta^R < 48^\circ$ ，以 G_-^R 描述 $48^\circ \leq \theta^R \leq 180^\circ$ ，兩段在 48° 連續銜接。軸心增益 G_{+i}^R 取自低軌換手情境下同級 0.6 m 使用者終端所採的降額值 [5]，較該孔徑的理想增益保守約 4.7 dB。該建議書只在 $\theta^R \geq \theta_-^R$ 定義此包絡（本文終端在 f_c 下 $\theta_-^R \approx 2.498^\circ$ ）；本文於 $\theta^R < \theta_-^R$ 延用同一包絡至 G_{+i}^R 截止，此為建模上的簡化，不在該建議書的規定範圍內。

wanted-link 的兩個線性功率增益因子仍直接相乘為

$$H_{u,s,v}(t) G^T(\theta_{u,s,v}, \theta_3). \quad (3.10)$$

其中 G^T 直接承載偏軸角， $H_{u,s,v}(t)$ 保留其餘通道因素的物理意義——包含式 (3.10b) 的四項損耗、接收增益，以及萊斯小尺度衰落（其 K 因子 K_R 屬情境校準，列於第 5.1 節）；兩者都是線性功率尺度的因子，不表示複數通道振幅。正文與簡化符號表、/ legacy

simulator 前端共用這個能和控制項/runtime 欄位對應的一層公開展開；三者只允許排版不同，不允許公式、符號或可調參數不同。公開展開的深度上限即 HOBS 正文所示的深度：式 (1) 的四項損耗，以及式 (3) 那一層的單一 J_1/J_3 角度型樣結構。更深的天線量測、Bessel 近似誤差與通道校準細節不屬於公開主公式層級；不另建立只靠大小寫區分的中間通道符號。另需注意 MODQN 的 $G_{i,l,v}$ 是通道增益，其角色對應本文的 $H_{u,s,v}$ ，與此處的天線增益 G^T 、 G^R 語意不同，不可同名合併。

3.1.3 Power, SINR and Throughput Model

以下只保留每一條 UE-衛星-波束鏈路的實際量。 $p_{u,s,v}$ 表示實際 RF 發射功率，不再由目標 SINR、最低速率或 lagged interference 反推；若程式需要標記 measured、predicted 或 cached provenance，該資訊放在資料欄位 metadata，不另建立第二個物理 SINR。

令 $\tau_{u,s,v}$ 為目前 uninterrupted served physical link (u,s,v) segment 的起始時間步。episode reset、handover、outage、unserved 與 re-entry 都會結束 continuity；新 segment 不保留 inactive-link cache，並以 p^0 起始。只有同一實體鏈路在前後兩步都被服務時，角度感知功率才使用 previous-step recurrence：

這是本研究自行定義的角度感知功率規則，不是原始 MODQN 的公式。其建模條件是同一連續服務段內維持發射功率與發射增益的乘積： $p_{u,s,v}(t, \theta_{u,s,v}(t), \theta_3) G^T(\theta_{u,s,v}(t), \theta_3) = p_{u,s,v}(t-1, \theta_{u,s,v}(t-1), \theta_3) G^T(\theta_{u,s,v}(t-1), \theta_3)$ 。把目前功率解出後，就得到下式；它只補償發射端角度增益，並不宣稱完整 SINR 或 throughput 固定。

$$p_{u,s,v}(t, \theta_{u,s,v}(t), \theta_3) = p_{u,s,v}(t-1, \theta_{u,s,v}(t-1), \theta_3) \frac{G^T(\theta_{u,s,v}(t-1), \theta_3)}{G^T(\theta_{u,s,v}(t), \theta_3)}, x_{u,s,v}(t-1) = x_{u,s,v}(t) = 1, G^T(\theta_{u,s,v}(t), \theta_3)$$

segment 起始與 segment 內的 closed form 為

$$p_{u,s,v}(\tau_{u,s,v}, \theta_{u,s,v}(\tau_{u,s,v}), \theta_3) = p^0, p_{u,s,v}(t, \theta_{u,s,v}(t), \theta_3) = p^0 \frac{G^T(\theta_{u,s,v}(\tau_{u,s,v}), \theta_3)}{G^T(\theta_{u,s,v}(t), \theta_3)}. \quad (3.12)$$

式 (3.12) 只有在 $\tau_{u,s,v}$ 到 t 的每一步都維持同一 served physical link 且角度增益為正時成立；它是式 (3.11) 的 telescoped identity，不是跨事件的 runtime state。這個關係表達前一步角度增益如何遞推實際鏈路 RF power，不引入目標 SINR、需求功率反推、beam/satellite cap、PA clamp 或 min/max 投影。

在系統層定義全體角度狀態 $\theta(t)$ ——即每一個 $u \in U, s \in S, v \in V$ 的偏軸角 $\theta_{u,s,v}(t)$ 所組成的集合——並令 $I_{u,s,v}(t, \theta_{u,s,v}, \theta_3)$ 表示相對於 wanted link 的總同頻干擾。

波束以三色頻率重用配置。令 $c_{s,v} \in \{0, 1, 2\}$ 為波束 (s, v) 的頻率顏色，依其地面蜂巢在六角格上的軸向座標 $(q_{s,v}, r_{s,v})$ 指派為 $c_{s,v} = (q_{s,v} - r_{s,v}) \bmod 3$ 。此規則使六角格上任兩個相鄰蜂巢必為異色：同色波束共用同一子頻帶，異色波束彼此正交。因此單一波束的可用頻寬為 $B^w = B^g/3$ ，而干擾只來自與服務波束同色且已啟用的其他波束。蜂巢排列與各波束的軸向座標屬環境設定，於第 5.1 節說明。

一支已啟用的波束以單一功率發射，不論其上載有幾位使用者；沿用執行端的聚合慣例令 $p_{s,v}(t, \theta, \theta_3) = \max_{u \in U: x_{u,s,v}(t)=1} p_{u,s,v}(t, \theta_{u,s,v}(t), \theta_3)$ 為該波束的發射功率。左側保留全系統角度狀態與固定波束寬參數，因為右側會在所有已服務鏈路中取最大值。參考 HOBS 與多波束低軌道衛星系統模型 [4], [20]，將干擾分為同衛星干擾與跨衛星干擾，分別如式 (3.12a) 與式 (3.12b)：

$$I_{u,s,v}^i(t, \theta_{u,s,v}, \theta_3) = \sum_{\substack{v' \in V, v' \neq v \\ c_{s,v'} = c_{s,v}}} z_{s,v'}(t) p_{s,v'}(t, \theta, \theta_3) G^T(\theta_{u,s,v}(t), \theta_3) H_{u,s,v'}(t), \quad (3.12a)$$

$$I_{u,s,v}^x(t, \theta_{u,s,v}, \theta_3) = \sum_{s' \in S, s' \neq s} \square \sum_{\substack{v' \in V \\ c_{s',v'} = c_{s,v}}} z_{s',v'}(t) p_{s',v'}(t, \theta, \theta_3) G^T(\theta_{u,s',v'}(t), \theta_3) H_{u,s',v'}(t), \quad (3.12b)$$

且 $I_{u,s,v}(t, \theta_{u,s,v}, \theta_3) = I_{u,s,v}^i(t, \theta_{u,s,v}, \theta_3) + I_{u,s,v}^x(t, \theta_{u,s,v}, \theta_3)$ 。每一項都以該干擾波束自己的偏軸角與線性鏈路因子計算，因為不同波束到同一位使用者的路徑損耗與增益都不同；求和以啟用指示 z 為門檻，而不是以其上載有幾位使用者為權重。

雜訊功率為 $\sigma^2 = k_B T B^w$ ，其中 k_B 為波茲曼常數， $T = T_a + T_0 (10^{N_f/10} - 1)$ 為接收系統溫度。 T_a 為天線溫度、 N_f 為接收機雜訊指數、 T_0 為雜訊指數的參考溫度，數值取自 3GPP TR 38.821 的 VSAT 設定 [22]，列於第 5.1 節。雜訊在整支波束的頻寬上積分，因此與該波束的載量無關。唯一的鏈路 SINR 為

$$\gamma_{u,s,v}(t, \theta_{u,s,v}, \theta_3) = \frac{p_{u,s,v}(t, \theta_{u,s,v}, \theta_3) H_{u,s,v}(t) G^T(\theta_{u,s,v}, \theta_3)}{I_{u,s,v}(t, \theta_{u,s,v}, \theta_3) + \sigma^2}, \quad (3.13)$$

其中 $I_{u,s,v}(t, \theta_{u,s,v}, \theta_3) + \sigma^2 > 0$ 。這個符號同時用於基線鏈路計算與角度感知功率替換；不另定義 estimated、required、target 或帶 serving-index 巢狀下標的 SINR。

波束內採時分多工，同一波束上的 $U_{s,v}(t)$ 位使用者依序使用可用頻寬。因此鏈路 throughput 為 [2], [4]

$$R_{u,s,v}(t, \theta_{u,s,v}, \theta_3) = \frac{B^w}{U_{s,v}(t)} \log_2(1 + \gamma_{u,s,v}(t, \theta_{u,s,v}, \theta_3)), U_{s,v}(t) > 0. \quad (3.14)$$

B^w 是單一波束可用頻寬；單一使用者展示時只令 $U_{s,v}=1$ ，不另建立第二套 rate 或 SINR 公式。連線變數 $x_{u,s,v}(t)$ 只負責選取實際服務鏈路，不另建立 user-level 的 SINR 或 throughput 別名。

一支波束由單一功率放大器驅動，因此電源端功率是逐波束而非逐鏈路的量。令 $\xi_{s,v}(t, \theta, \theta_3) > 0$ 為該波束由 RF power 到電源端消耗的有效轉換效率，則

$$P_{s,v}^p(t, \theta, \theta_3) = \frac{p_{s,v}(t, \theta, \theta_3)}{\xi_{s,v}(t, \theta, \theta_3)}. \quad (3.15)$$

發射出去的功率不等於實際耗掉的功率。波束的射頻訊號由功率放大器產生，其射頻輸出與所取用直流功率之比即為式 (3.15) 的 ξ 。放大器接近飽和點時效率較高但較不線性，因此實務上退離飽和點一段距離運作，該距離稱為輸出回退 b_o （以 dB 表示）：飽和功率為 $p^s = p^{+10^{b_o/10}}$ ，其中 p^{+} 是回退後的每波束操作上限。參考傳統類 B 功率放大器的功率與效率關係 [23]，以負載相依的平方根曲線近似回退區的效率變化；這是便於系統層分析的工程近似，不是完整的電路模型：

3

平方根可由類 B 的理想近似理解：令 V_o 為輸出電壓振幅，在固定供應電壓與負載下射頻輸出功率滿足 $p_{s,v} \propto V_o^2$ ，平均直流輸入功率則近似滿足 $P_{s,v}^p \propto V_o$ ，因此 $\xi = p_{s,v} / P_{s,v}^p \propto \sqrt{p_{s,v}}$ 。射頻輸出為飽和功率的四分之一時，效率是 $\xi^{+1/2}$ 而不是 $\xi^{+1/4}$ 。 ξ^{+} 與 b_o 的數值列於第 5.1 節；Ka 頻段衛星下行 GaN Doherty MMIC 的實測飽和功率附加效率為 23–31%，6 dB 輸出回退時約 20% [24]，與本模型的量級一致，但並非同一測量點。Morello 與 Mignone 的雙載波 DVB-DSNG 範例對每一載波採 5.5 dB 輸出回退 [25]，說明多載波操作為維持準線性區需要較大的回退；該敘述不足以泛化到所有多載波系統，此處僅作為回退量級的旁證。

這個形狀有一個對本論文重要的後果：由於低輸出時效率較差，把發射功率壓低並不會等比例降低功率消耗。真正影響能量效率的是「用多少功率換到多少吞吐量」，這也是第 3.2 節把能量效率而非單純發射功率作為第一個目標的理由。

令 $P^f(t)$ 彙總所有不直接由偏軸角控制的 fixed / circuit overhead。令 $N_s^a(t) = \sum_{v \in V} z_{s,v}(t)$ 為衛星 s 的啟用波束數；本研究將一支啟用波束對應到一條射頻鏈，則

$$P^f(t) = \sum_{s \in S} \left(N_s^a(t) P^c + 1 \left[N_s^a(t) > 0 \right] P^b \right). \quad (3.16a)$$

基頻功率由該衛星的所有啟用波束共用，因此每顆衛星只計一次，不會重複計入。 P^c 與 P^b 的數值取自 You 等人 Table II [26]，列於第 5.1 節。「一支波束對應一條射頻鏈」是本研究的對應設定，不是該文的衛星架構結論；該文另含本振功率與相移器功率，本研究不納入，因此式 (3.16a) 是 partial payload-power model，不是完整的衛星總功率模型。系統總功率為

$$P^N(t, \theta, \theta_3) = P^f(t) + \sum_{s \in S} \sum_{v \in V} z_{s,v}(t) P_{s,v}^p(t, \theta, \theta_3). \quad (3.16)$$

此處對 (s, v) 求和而非對 (u, s, v) 求和：一支已啟用的波束只有一個放大器，其電源端功率不隨波束上載有幾位使用者而重複計入，這與式 (3.12a) 的 $p_{s,v}$ 聚合一致。若改為逐鏈路加總，多出的項為 $\sum_{s,v} (U_{s,v}(t) - 1) P_{s,v}^p(t, \theta, \theta_3)$ ，隨佔用人數單調上升，會使第一目標重複承擔第三目標的工作。

最後，固定鏈路 (u, s, v) 的 EE 顯示量定義為

$$\eta_{u,s,v}(t, \theta_{u,s,v}, \theta_3) = \frac{R_{u,s,v}(t, \theta_{u,s,v}, \theta_3)}{P^N(t, \theta, \theta_3)}, P^N(t, \theta, \theta_3) > 0. \quad (3.17)$$

這裡的三下標固定分子的 UE-link；分母仍是共同系統功率，因此 $\eta_{u,s,v}$ 是單一 UE-link 對系統 EE 的顯示量／貢獻，不宜稱為 private-power 的 true per-user EE。

本研究採用的多目標深度 Q 網路 (MODQN) 基準，以三個 Q 網路分別學習三個目標；其中吞吐量原本是第一個獎勵項 [2]。本文將第一個獎勵定義為所選鏈路 EE 貢獻的總和，使模型同時考慮傳輸量、波束角度與功率消耗。

3.2 Problem Formulation

本研究同時考慮能量效率、換手成本與負載平衡。令 L_w 為每個時間步納入決策的可見衛星數。以實際連線 $x_{u,s,v}(t)$ 為決策結果，長期目標可寫為 [2]

$$\begin{aligned}
P1: & \wedge \max \sum_t \sum_{u \in U} r_{1,u}(t, \theta, \theta_3), \\
P2: & \wedge \min \sum_t \sum_{u \in U} \Psi_u(t), \\
P3: & \wedge \min \sum_t \sum_{s \in S} \sum_{v \in V} U_{s,v}(t)^2, \\
s.t.: & \wedge x_{u,s,v}(t) \in \{0, 1\}, \sum_{s \in S} \sum_{v \in V} x_{u,s,v}(t) \leq 1.
\end{aligned} \tag{3.24}$$

P1 希望在相同耗能下傳送更多資料，P2 減少換手，P3 則使各波束承載的使用者數趨於平均：在總服務人數固定時，平方和的最小值恰為各波束人數相差至多一人的配置。以下分別定義三個目標。

3.2.1 Angle-Aware Energy Efficiency

式 (3.15)–(3.17) 已先定義鏈路耗電、共同系統功率與固定鏈路 EE 顯示量。第一個獎勵則把使用者實際選取的鏈路 EE 貢獻相加：

$$\begin{aligned}
& r_{1,u}(t, \theta, \theta_3) \wedge \sum_{s \in S} \sum_{v \in V} x_{u,s,v}(t) \eta_{u,s,v}(t, \theta_{u,s,v}, \theta_3) \\
& = \frac{\sum_{s \in S} \sum_{v \in V} x_{u,s,v}(t) R_{u,s,v}(t, \theta_{u,s,v}, \theta_3)}{P^N(t, \theta, \theta_3)}, P^N(t, \theta, \theta_3) > 0.
\end{aligned} \tag{3.25}$$

$r_{1,u}(t, \theta, \theta_3)$ 的單位為 bit/J，表示使用者 u 對瞬時系統能量效率的可加貢獻。式 (3.25) 只在共同系統功率為正時成立；未選取的鏈路由 $x_{u,s,v}(t)=0$ 排除。這裡不另建立 user-level SINR 或 user-level throughput 符號。

因此，角度直接進入 G^T ，而式 (3.13) 的 wanted-link numerator 使用 $p_{u,s,v} H_{u,s,v} G^T(\theta_{u,s,v}, \theta_3)$ ；式 (3.11)–(3.12) 以 segment-start p^0 與 previous-step recurrence 決定角度相關鏈路 RF power。同一個 p 也進入總干擾所對應的系統狀態，以及式 (3.15)–(3.17) 的功率與 EE。主公式不需要目標 SINR、需求功率反推或保護性 cap。

3.2.2 Handover Cost

沿用上述 $(\rho_u(t), \delta_u(t))$ 表示的服務衛星與波束。同衛星換束的成本為 φ_1 ，跨衛星換手的成本為 φ_2 ，且 $0 < \varphi_1 < \varphi_2$ 。第二個獎勵為

$$r_{2,u}(t) = -\Psi_u(t), \Psi_u(t) = \begin{cases} 0, & (\rho_u(t), \delta_u(t)) = (\rho_u(t-1), \delta_u(t-1)), \\ \varphi_1, & \rho_u(t) = \rho_u(t-1), \delta_u(t) \neq \delta_u(t-1), \\ \varphi_2, & \rho_u(t) \neq \rho_u(t-1). \end{cases} \quad (3.27)$$

因此，維持原連線時不產生成本，同衛星換束次之，跨衛星換手的成本最高。

3.2.3 Load Balancing

第三個獎勵取使用者所選波束當步服務人數的負值；該人數即式 (3.3) 定義的 $U_{s,v}(t)$ ：

$$r_{3,u}(t) = -U_{b_u(t)}(t). \quad (3.28)$$

其中 $b_u(t)$ 為使用者 u 當步所選的波束， $U_{b_u(t)}(t)$ 為該波束當步服務的使用者數（式 (3.3)）。所選波束越擁擠，獎勵越低。此獎勵逐使用者可分解：由 $\sum_{u \in U} U_{b_u(t)}(t) = \sum_{s,v} U_{s,v}(t)^2$ ，所有使用者的獎勵總和恰為 P3 目標的負值，故每位使用者的獎勵是全域目標的精確分解，不同於舊式以系統層級純量共享給所有使用者的作法。

3.2.4 Reward Vector and Evaluation Metric

MODQN 保留三維獎勵向量 [2]：

$$\vec{R}_u(t, \theta, \theta_3) = [r_{1,u}(t, \theta, \theta_3), r_{2,u}(t), r_{3,u}(t)]. \quad (3.29)$$

三個分量的引數不同： $r_{1,u}$ 透過 $\eta_{u,s,v}$ 與 P^N 依賴整組偏軸角與波束寬參數，故帶 θ, θ_3 ； $r_{2,u}$ 只由服務衛星與波束的變動決定、 $r_{3,u}$ 只由佔用人數決定，兩者都不含角度。向量本身因第一個分量而帶 θ, θ_3 。第四章的通式 $r_{j,u}$ 與 $\dot{r}_{j,u}$ 不逐項分寫引數，各分量沿用此處的定義。

訓練使用逐步獎勵；跨時間的總位元／總能量評估屬於第五章的實驗評估程序，不在本節再建立第二個 EE 物理符號。第五章另行說明評估時間範圍、服務品質、覆蓋與換手指標，並將它們與式 (3.17) 的當步鏈路 EE 區分。

MODQN 讓每位使用者各自選取加權 Q 值最高的可行波束。狀態相近的使用者可能共同集中到少數波束；由式 (3.14)，同一波束上的使用者均分頻寬，集中會直接壓低每個人的速率，也使式 (3.24) 的 P3 目標惡化。第四章將以兩種訓練塑形策略處理這個問題。

4. Multi-Catfish Reinforcement Learning (MCRL)

4.1 Method Overview

第三章以實際連線 $x_{u,s,v}(t)$ 描述物理系統。本章則要把可選波束整理成神經網路可處理的固定動作空間，並說明 MODQN 與 MCRL 如何使用這些資訊。

低軌衛星持續移動，每位使用者可選的實際波束會改變，但神經網路的輸出長度必須固定。因此，每位使用者使用一張固定長度的候選表。表中保留 L_w 顆可見衛星，每顆衛星提供 J_w 個候選波束，共有 $C=L_w J_w$ 個位置。令 $C=\{1,\dots,C\}$ 為候選編號集合， $c\in C$ 表示表中的一個位置。

候選表的內容會隨時間更新。 $b_u(c,t)\in S\times V$ 表示候選位置 c 在時間 t 對使用者 u 所對應的實際衛星與波束。後續網路選的是候選編號，實際連線則透過 $b_u(c,t)$ 回到第三章的衛星一波束索引。

這張候選表是本論文為固定網路輸出所建立的表示法。原始 MODQN 論文把狀態與 access action 寫在完整的 $L\times V$ 波束位置網格上；本論文則將移動中的可見視窗限制為 $L_w\times J_w$ 個候選。

使用者的狀態包含四類資訊：前一步的連線、各候選鏈路的訊號品質、各候選的偏軸角以及前一步選向各波束的使用者數。將它們依候選表順序排列後，狀態寫成

$$s_u(t) \triangleq \text{concat} \left(x_u(t-1), \left(\gamma_{u,s,v}(t, \theta_{u,s,v}, \theta_3) \right)_{\substack{(s,v)=b_u(c,t) \\ c\in C}}, \left(\theta_{u,s,v}(t) \right)_{\substack{(s,v)=b_u(c,t) \\ c\in C}}, N_u(t-1) \right). \quad (4.1)$$

其中， $x_u(t-1) = (x_{u,b_u(c,t)}(t-1))_{c\in C}$ 記錄前一步的連線。兩個圓括號序列依候選順序排列三下標的鏈路 SINR 與偏軸角元素，*concat* 再把四個區塊接成一個狀態向量；SINR 沿用第三章唯一的 $\gamma_{u,s,v}$ 定義。這些值在動作前由環境可取得；若實作使用 *cached* 或 *predicted provenance*，該標記放在資料欄位 *metadata*，不改變公式中的物理符號。候選表在時間 t 的排列必須讓上一步實際服務的波束仍可辨識：若使用者 u 在 $t-1$ 被服務，其服務波束 $(\rho_u(t-1), \delta_u(t-1))$ 必須仍占有某一個候選位置， $x_u(t-1)$ 才能還原出式 (3.27) 所需的前一步實體關聯；若該波束已離開候選表，則本步無論選哪一格都構成換手。

令 $n_{s,v}(t-1)$ 表示前一步選向波束 (s,v) 的使用需求量。 $N_u(t-1) = \mathbf{i}$ 是依候選順序排列的向量；式 (3.3) 的 $U_{s,v}(t)$ 則表示實際服務負載。

式 (4.1) 只使用選擇動作前可取得的資訊；本步動作造成的連線、負載、SINR 與吞吐量則用於產生本步獎勵及下一步狀態。

候選表的長度固定，但部分位置在當下可能不可用。以 $m_u(t)$ 表示可行動作遮罩：

$$m_u(t) = (m_{u,1}(t), m_{u,2}(t), \dots, m_{u,C}(t)), m_{u,c}(t) \in \{0, 1\}, \quad (4.2)$$

$$A_u(t) = \{c \in C \mid m_{u,c}(t) = 1\}. \quad (4.3)$$

其中， $m_{u,c}(t) = 1$ 表示候選 c 可選，0 表示不可選； $A_u(t)$ 收集所有可選的候選編號。政策輸出的是純量候選編號 $a_u(t)$ ；環境套用動作時，才使用它在候選 c 上的 one-hot 編碼 $a_{u,c}(t)$ 。

使用者 u 選出的候選編號記為純量 $a_u(t)$ 。為了讓環境逐一套用到候選位置，將它展開為 one-hot 指示量 $a_{u,c}(t)$ ；候選 c 被選中時該分量才為 1：

$$a_u(t) \in A_u(t), a_{u,c}(t) = 1 \mid c = a_u(t), c \in C. \quad (4.4)$$

可行動作集合非空時，每位使用者在一個時間步選擇一個候選；可行動作集合為空時沒有任何候選可選，因此

$$\sum_{c \in C} a_{u,c}(t) = \begin{cases} 1, & A_u(t) \neq \emptyset, \\ 0, & A_u(t) = \emptyset, \end{cases} a_{u,c}(t) \in \{0, 1\}. \quad (4.5)$$

$A_u(t) = \emptyset$ 時式 (4.4) 的 $a_u(t) \in A_u(t)$ 無解，該步不執行任何候選：使用者 u 於該步 unserved，其所有 $x_{u,s,v}(t)$ 為 0，該步的轉移不進入經驗回放。本設定不宣稱遮罩恆為非空，因為候選格覆蓋與鏈路可行性可能在同一步同時排除所有候選。

決策時的遮罩 $m_{u,c}(t)$ 與實體波束啟用變數 $z_{s,v}(t)$ 的功能不同：前者決定使用者能選什麼，後者由式 (3.4) 的啟用規則決定該實體波束是否輻射。實際連線為

$$x_{u,b_u(c,t)}(t) = a_{u,c}(t) z_{b_u(c,t)}(t). \quad (4.5a)$$

因此，候選必須被選中且對應波束確實在輻射，使用者才會連上該波束。連上之後仍須滿足鏈路可行性：所需功率超過每波束上限者判為不可行，該使用者於該步為 outage。所有使用者在同一時間步的選擇合稱為聯合動作：

$$a(t) = (a_1(t), a_2(t), \dots, a_U(t)). \quad (4.6)$$

各波束依有效選擇形成啟用結果，其啟用狀態由式 (3.4) 決定。接著由式 (4.5a) 得到實際連線，再計算下一個狀態與三個獎勵。

以上狀態、動作、獎勵向量、環境轉移與折扣因子共同構成多目標馬可夫決策過程。

原始 MODQN 為三個目標各建立一個 Q 網路，得到 $\vec{Q}(s_u, a) = [Q_1(s_u, a), Q_2(s_u, a), Q_3(s_u, a)]$ [2]。三個 Q 值以權重 $\Omega = [\omega_1, \omega_2, \omega_3]$ 加權後，每位使用者從 $A_u(t)$ 中選出綜合價值最高的動作；訓練期間再加入 ϵ -greedy 探索。各 Q 網路使用自己的目標獎勵進行時間差分更新。權重的具體設定列於第 5.1 節。

MCRL 沿用 MODQN 的三個目標 Q 網路與逐使用者 $\arg \max$ 選擇。經驗塑形與獎勵塑形只在訓練期間作用，分別調整訓練經驗與鯊魚代理的第一個獎勵；部署時的輸入表示與選法都與 MODQN 相同。

圖 4-1 標示各機制在資料蒐集與參數更新中的作用位置。




Fig. 4-1 Intervention points in the MODQN update

圖 4-1：MCRL 在 MODQN 更新流程中的作用位置。能效分層與競爭獎勵處理鯊魚代理經驗，週期性介入提供主代理的混合批次，非對稱折扣區分兩個代理的回合內回報加權。

圖 4-2 以目標網路為單位呈現主代理與鯊魚代理的對應關係。




Fig. 4-2 Objective-network view of MCRL

圖 4-2：主代理與鯰魚代理各含三個目標 Q 網路， $Q_j^M \leftrightarrow Q_j^F \leftrightarrow r_j$ 一一對應。每個代理以共同權重 Ω 純量化三個 Q 值後選擇動作。

圖 4-3 補充兩個代理的軌跡、經驗池與週期性介入關係。




Fig. 4-3 Role-level MCRL training architecture

圖 4-3：主代理與鯰魚代理各自產生訓練軌跡並維護經驗池。鯰魚端的三目標轉移依第一目標分流，週期性介入再以混合批次更新主代理；訓練完成後只部署主代理。

4.3 Experience Shaping with the Catfish Agent

本節說明 MCRL 如何在三目標換手問題中使用鯰魚輔助角色。

主代理和鯰魚代理各是一組三目標 MODQN。兩端都使用三個線上 Q 網路和三個目標網路， Q_j^M 與 Q_j^F 分別對應同一個目標 r_j ，其中 $j=1,2,3$ 依序代表能量效率、換手和負載平衡。兩端各自學習自己的軌跡和經驗；每一端的三個目標網路沿用深度 Q 網路的訓練流

程 [27]，共用該端的狀態、動作、轉移與經驗池，再讀取獎勵向量中各自的第 j 個分量。訓練時共有兩組 MODQN；完成訓練後只保留主代理。

三個獎勵的單位和量級不同。環境產生獎勵後、寫入經驗池前，第 j 個分量先除以固定正數 c_j ，亦即 $\dot{r}_{j,u}^d = r_{j,u}^d / c_j$ ；完整更新式列於式 (4.13)。本文將未加入式 (4.11) 競爭項、但已完成尺度校準的獎勵稱為「未整形獎勵」。

主代理經驗池 D_M 儲存未整形且已校準的三維獎勵。鯰魚經驗池 D_F 同時保留未整形與競爭整形後的校準視圖：鯰魚代理 TD 更新使用整形視圖，週期性介入抽出的鯰魚樣本則使用未整形視圖。只有能效分層的門檻直接使用校準前的第一目標。兩個經驗池都以包含全體使用者的完整時間步轉移為單位。

經驗塑形由三個部分組成：能效分層負責篩選鯰魚經驗，非對稱折扣改變鯰魚代理在回合內對各步回報的加權，週期性介入則把部分鯰魚經驗用於主代理的額外更新。

第一個部分是能效分層。鯰魚代理在每一步產生一筆包含全體使用者和三維獎勵的完整轉移束 τ_t^F 。令分層分數為該步校準前、未整形第一目標的平均可加貢獻： $g^F(t, \theta, \theta_3) = U^{-1} \sum_{u \in U} r_{1,u}^F(t, \theta, \theta_3)$ 。此分數再和最近 W 束分數的經驗分布 F_W 比較。此分數僅用於訓練分層，不作為評估指標。對 $q \in (0, 1)$ ， $F_W^{-1}(q)$ 是經驗分布的 q 分位數，表示約有比例 q 的近期分數不高於該門檻。令 q_1 和 q_2 滿足 $0 < q_1 < q_2 < 1$ ，分流規則如下：

$$routing(\tau_t^F) = \begin{cases} D_F, & g^F(t, \theta, \theta_3) \geq F_W^{-1}(q_2), \\ D_M, & F_W^{-1}(q_1) \leq g^F(t, \theta, \theta_3) < F_W^{-1}(q_2), \\ \emptyset, & g^F(t, \theta, \theta_3) < F_W^{-1}(q_1). \end{cases} \quad (4.7)$$

高分轉移束放入 D_F ，中間分數的轉移束另外送入 D_M ，低分轉移束則捨棄。分流雖然只看校準前的第一個目標，保留的仍是完整三目標轉移；寫入經驗池的獎勵則使用前述校準後的視圖。




Fig. 4-4 Energy-efficiency stratification

圖 4-4：能效分層。鯰魚代理的轉移束 τ_t^F 先以校準前的平均未整形第一目標貢獻 $g^F(t, \theta, \theta_3)$ 評分，再和近期分布 F_W 比較。高分放入 D_F ，中間分數另外送入 D_M ，低分捨棄（式 (4.7)）；保留後再由各經驗池使用相應的校準獎勵視圖。

第二個部分是非對稱折扣。主代理的三個目標共用 β_M ，鯰魚代理的三個目標共用較大的 β_F ：

$$\beta_M < \beta_F, \beta_j^M \equiv \beta_M, \beta_j^F \equiv \beta_F, j=1, 2, 3. \quad (4.8)$$

折扣因子越大，回合內較後步驟的回報保留得越多。在本文的回合長度 $H=10$ 下，兩端的有效視野皆不短於回合本身（ $1/(1-\beta_M)=10$ ），故差異體現為回合內各步權重的分配：主代理較重視近期回報，鯰魚代理則接近均勻計入整個回合。回合長度與 β_M 的有效視野一致，均為 10 步，此為原論文 Table I 的設定，不構成偏離。




Fig. 4-5 Asymmetric discounting

圖 4-5：非對稱折扣。主代理的三個目標網路使用 β_M ，鯰魚代理的三個目標網路共同使用較大的 β_F （式 (4.8)）。未來第 n 步回報的相對權重為 β^n ，圖中長條只表示權重衰減。

第三個部分是週期性介入。每次從整數區間 $[T_1, T_2]$ 均勻抽取介入間隔 T 。間隔到期時，從 D_F 取出比例 ρ_I 的樣本，和 D_M 的樣本合成一個混合批次 B_I ：

$$\begin{aligned} n_F &\wedge \text{round}(\rho_I B), \\ n_M &\wedge B - n_F. \end{aligned} \quad (4.9)$$

其中 B 是批次大小， $\text{round}(\cdot)$ 表示取最近整數。由 D_M 抽取 n_M 筆樣本、由 D_F 抽取 n_F 筆樣本，合併成混合批次 B_I ；兩類樣本都使用未整形且已校準的三維獎勵。主代理的三個目標網路共同使用 B_I ，並以 β_M 額外更新一次；介入後重新抽取 T 。

Periodic intervention

training only




Fig. 4-6 Periodic intervention

圖 4-6：週期性介入。以 n_M 筆主代理樣本和 n_F 筆鯰魚代理樣本組成 B_I （式 (4.9)）；兩者都使用未整形且已校準的獎勵，再以同一批資料更新 Q_1^M 、 Q_2^M 、 Q_3^M 。

三個部分共同完成經驗塑形，且都只改變訓練；部署時仍由主代理選擇動作。

兩端的選動作方式相同。令 $d \in \{M, F\}$ 表示主代理端或鯰魚代理端， $A_u^d(t)$ 表示使用者 u 在該端的可行動作集合。兩端都用第 3.2 節的共同權重 $\Omega = [\omega_1, \omega_2, \omega_3]$ 合成三個 Q 值，再從這個集合中選動作；訓練時另外加入各端自己的 ϵ -greedy 探索：

$$V_u^d(a, t) = \sum_{j=1}^3 \omega_j Q_j^d(s_u^d(t), a), a_u^d(t) = \arg \max_{a \in A_u^d(t)} V_u^d(a, t), d \in \{M, F\}. \quad (4.10)$$

式 (4.10) 表示兩組 MODQN 的一一對應關係。 Q_j^M 和 Q_j^F 估計同一個目標，兩端都把三個目標值合成一個綜合價值 $V_u^d(a, t)$ 。因為兩端獨立學習，所以可能選出不同動作。每一端的三個網路共用該端選出的動作，但各自保留網路參數。這些 Q 網路以校準後的獎勵訓練，因此原始單位下的實際取捨權重為 ω_j/c_j 。

4.4 Reward Shaping: the Competitive Reward Mechanism

本節定義鯰魚代理使用的第一個獎勵。競爭獎勵機制 (ACRM) 比較鯰魚代理和主代理在能量效率目標上的表現。換手和負載平衡不加入競爭項，但寫入經驗池前仍依相同的 c_j 校準。

ACRM 在相同的動作前狀態和隨機條件下比較兩個完整聯合動作。鯰魚代理依式 (4.10) 產生 $a_F(t)$ ，主代理則產生不含探索的貪婪動作 $a_{M|F}(t)$ 。兩次模擬只有聯合動作不同，第一目標都依式 (3.25) 計算。令原始獎勵為 $r_{1,u}^F(t, \theta, \theta_3)$ 和 $r_{1,u}^{M|F}(t, \theta, \theta_3)$ ，接著定義競爭差值和整形獎勵：

$$r_{1,u}^S(t, \theta, \theta_3) = r_{1,u}^F(t, \theta, \theta_3) - r_{1,u}^{M|F}(t, \theta, \theta_3), r_{1,u}^C(t, \theta, \theta_3) = r_{1,u}^F(t, \theta, \theta_3) + \eta_w r_{1,u}^S(t, \theta, \theta_3). \quad (4.11)$$

其中 $\eta_w \geq 0$ 是競爭權重。兩個原始 r_1 都先依式 (3.25) 計算，再形成差值。 $r_{1,u}^S > 0$ 表示鯰魚代理在相同條件下的能效較高， $r_{1,u}^S < 0$ 則相反。當 $\eta_w = 0$ 時， $r_{1,u}^C = r_{1,u}^F$ 。

鯰魚代理的整形向量為 $[r_{1,u}^C, r_{2,u}^F, r_{3,u}^F]$ 。ACRM 先在原始單位下形成 $r_{1,u}^C$ ，再校準整個向量。能效分層仍以校準前的 $r_{1,u}^F$ 評分；送入 D_M 的樣本與介入批次 B_I 使用未整形的校準視圖；鯰魚代理 TD 更新則使用整形後的校準視圖。因此，競爭項只影響 Q_1^F 。




Fig. 4-7 Competitive reward mechanism

圖 4-7：能效軸的競爭獎勵。在相同的動作前狀態和隨機條件下只改變完整聯合動作；兩次模擬依式 (3.25) 計算第一目標，再形成 $r_{1,u}^S$ 和 $r_{1,u}^C$ （式 (4.11)）。整形與未整形向量之後都依式 (4.13) 校準，只有 Q_1^F 使用競爭整形後的值。

4.5 Overall Training Procedure

主代理與鯰魚代理各自產生訓練軌跡。競爭獎勵使用更新前的主代理價值進行配對比較當步完成分流的經驗則供後續參數更新使用。

偽程式碼 4-1 整理完整訓練順序。 E 與 H 分別為訓練回合數與每回合最大時間步， B 為 TD 批次大小， K 為目標網路同步週期。介入間隔 T 依式 (4.9) 所述範圍抽取。

#	偽程式碼 4-1：MCRL 訓練流程
	輸入： 兩組 MODQN 與式 (4.7)–(4.16) 所需的訓練設定。 輸出： 訓練後的主代理 Q^M 。
1	初始化兩端的線上與目標網路、經驗池 D_M, D_F ，並抽取第一個介入間隔 T 。
2	for $e=1, \dots, E$ do ：初始化主代理與鯰魚代理的兩條訓練軌跡。
3	for $t=1, \dots, H$ do ：依式 (4.7)–(4.9) 建立兩端輸入。
4	兩端依式 (4.10) 與 ϵ -greedy 分別選出聯合動作。
5	執行主代理動作得到 τ_t^M ，校準未整形獎勵後將完整轉移存入 D_M 。
6	執行鯰魚代理動作得到 τ_t^F ；在相同動作前狀態下評估主代理的貪婪動作，並依式 (4.11) 形成競爭獎勵。
7	以校準前的第一目標依式 (4.7) 分流 τ_t^F ；送往 D_M 的樣本使用未整形校準視圖，鯰魚端 TD 更新使用整形校準視圖。
8	若經驗數足夠，分別以 β_M 與 β_F 更新主代理與鯰魚代理。
9	介入間隔到期時，依式 (4.9) 形成 B_t ，對主代理額外更新一次，並重新抽取 T 。
10	若本回合終止，離開時間步迴圈。
11	每經過 K 回合，同步兩端的目標網路。

主代理的 TD 更新讀取未整形的校準向量；鯰魚代理的 TD 更新讀取 $[r_{1,u}^C, r_{2,u}^F, r_{3,u}^F]$ 校準後的向量。在此令 $d \in \{M, F\}$ 表示主代理或鯰魚代理，並以 β_d 表示該端的折扣因子。兩端沿用原論文式 (16) 的形式，每個目標各自在自己的目標網路上取最大值：

$$y_{j,u}^d = \begin{cases} \dot{r}_{j,u}^d(t), & s_u^d(t+1) \text{ is a terminal state, } d \in \{M, F\}, j=1,2,3. \\ \dot{r}_{j,u}^d(t) + \beta_d \max_{a' \in A_u^d(t+1)} Q_j^d(s_u^d(t+1), a', \theta_j^{d,-}), & \text{otherwise,} \end{cases} \quad (4.12)$$

若下一個狀態是終止狀態，TD target 只有當步獎勵；否則再加上折扣後的目標網路價值，且每個目標各自在自己的目標網路上取最大值。主代理與鯰魚代理各自做一次 TD 更新；週期性介入則用 B_I 對主代理額外做一次 TD 更新。

訓練端每個目標各自取最大值，與部署端式 (4.10) 以 Ω 純量化後取 $\arg \max$ 是兩件不同的事；這是原論文的设计, 本文沿用, 不另行更動。

三個獎勵的單位和量級不同：第一個的單位為 bit/J，第二個是換手成本，第三個是波束服務人數的計數。下列校準是本論文自己定義的訓練契約，不是原始 MODQN 論文明確寫出的公式。原論文保存原始 reward components，再直接以 Ω 對學到的 Q 值做純量化，沒有引入 c_j 。本論文為了讓三個目標以固定且明確宣告的尺度進入訓練，加入 c_j ；因此樣本放入經驗池前先除以固定的校準常數 c_j ：

$$\dot{r}_{j,u}^d(t) = \frac{r_{j,u}^d(t)}{c_j}, c_j > 0, j \in \{1, 2, 3\}, \quad (4.13)$$

其中 $r_{j,u}^d(t)$ 是端 d 校準前的第 j 個更新獎勵， $\dot{r}_{j,u}^d(t)$ 是校準後的值。訓練開始前固定 c_j ，並由各訓練程序共用。這樣式 (4.10) 的純量化和式 (4.12) 的 TD target 都使用同一尺度；原始單位下的實際取捨權重為 ω_j/c_j 。

部署時只保留主代理的三個目標網路。每位使用者依式 (4.10) 計算綜合價值，並以 $\arg \max$ 選出服務波束。

5. Experimental Results

5.1 Simulation Settings

本章說明模擬環境、索引域、通道與能耗模型，以及訓練和評估設定。第三章的 active EE 主鏈是唯一的公式契約；本章只補充數值情境與實驗評估範圍，不重新定義 SINR、throughput 或 EE。

表 5-1 列出環境與索引域的數值設定。第三章的 v 表示一個波束索引， V 表示每顆衛星的波束位置數；本研究設定 $V=39$ 。表中的 U 、 S 、 V 與 C 分別對應各集合的元素數。

表 5-1：環境與索引域設定

類別	符號或關係	本研究設定
衛星星系	S	真實 Starlink 星曆（TLE 搭配 SGP4），373 個每日檔，涵蓋 2025-07-27 至 2026-08-20；傾角約 53 度
衛星高度	h_s	由星曆決定，不是設定值。語料期間逐日高度中位數為 483.0 km，該逐日中位數的範圍為 470.7–539.7 km；個別衛星的瞬時高度分布比此範圍寬
可見衛星視窗	L_w	4
地面使用者	U	100
每顆衛星的波束指向位置	V	39。在 $h_s=483$ km 的格陣上直接量測，39 格覆蓋服務區的 95.2%。格陣以 R_b 為六角格的外接圓半徑鋪設，格心間距 $\sqrt{3}R_b=24.24$ km、單格面積 509.0 km^2 ，使每格內接於自身的 3 dB 等高線而不留覆蓋洞。以該面積作面積比估算得

類別	符號或關係	本研究設定
		$18000 \times 0.95 / 509.0 = 33.6$
每顆視窗衛星的局部候選排名	J_w	格，低於量測值，因為它忽略格陣裁切到矩形服務區時的邊緣溢出；以量測值為準 7（最接近使用者的波束位置及其六個相鄰位置）
候選動作域	$C = L_w J_w$	$4 \times 7 = 28$
視窗內可指向組合	$L_w V$	$4 \times 39 = 156$ 個衛星一波束位置組合
時間離散化	Δt 、 H	每步 30.08 s；每回合 10 步

表中的兩個數字分別代表不同的模型對象：156 是視窗內可指向的衛星一波束位置總數，28 是每位使用者可選的候選動作數。

在 $C=28$ 下，式 (4.1) 的四類原始分量——前一步連線、候選 SINR、偏軸角與前一步需求——各有 28 個元素，因此 Q 網路輸入 s_u 為 $4C=112$ 維。

表 5-2 列出第三章通道與能耗模型的實驗校準值。正文主鏈使用 $G^T(\theta, \theta_3)$ 、不直接承載 wanted-link 角度型樣的線性鏈路功率因子 $H_{u,s,v}(t)$ 、角度相關 $p_{u,s,v}$ 、逐波束的 $P_{s,v}^p$ 、 P^f 與 P^N ；表中的細部通道設定只用於情境校準，不會擴張主公式。

表 5-2：通道與能耗模型設定

類別	符號或關係	本研究設定
載波與頻寬	f_c 、 B^g	20 GHz、500 MHz
大氣氣體吸收	$L_g(\alpha) = A^z / \sin \alpha$	$A^z = 0.25$ dB。式的形式取 TR 38.811 式 (6.6-8) [17]；天頂值由 TR 38.821 [22] 的 LEO Ka 頻段 20 GHz 下行鏈路預算反推，該表大氣損耗為 0.5 dB、LEO 目標仰角為 30 度

類別	符號或關係	本研究設定
閃爍	$L_c(\alpha)$	TR 38.811 表 6.6.6.2.1-1 [17] 的 20 GHz 對流層閃爍：仰 角 90 度 0.12 dB、30 度 0.30 dB、10 度 1.08 dB。同 文件 §6.6.6.1 說明電離層閃 爍只在 6 GHz 以下考慮，本 研究在 20 GHz 故不計
遮蔽衰落	$L_s(\alpha)$	TR 38.811 表 6.6.2-3 [17] 的 Ka 頻段 LOS shadow fading，零均值、dB 域高 斯，標準差由仰角 90 度的 0.4 dB 至 10 度的 1.9 dB。clutter loss 只在 NLOS 適用，固定終端取 LOS 故 不計
頻率重用	$c_{s,v}、B^w$	3 色重用；166.667 MHz
波束寬與覆蓋半徑	$\theta_3、R_b=h_s \tan(\theta_3/2)$	3.32 度；在 $h_s=483$ km 時 為 13.998 km
波束中心增益	G_0	2000（線性），即 33.010 dBi
接收增益上下限	$G_{+c}^R、G_{-}^R$	35 dBi、-10 dBi；式 (3.10c) 的截止值
接收增益包絡	$A_R、B_R$	32、25；式 (3.10c) 的地球 站參考型樣參數，併入 $H_{u,s,v}(t)$
軸心極限閾值	ϵ_μ	10^{-10}
Rician 衰落	K_R	20 dB
接收系統溫度	$T_a、T_0、N_f、T$	150 K、290 K、1.2 dB、242.294 K

類別	符號或關係	本研究設定
固定功率	$P^f(t)$	由射頻鏈、基頻與其他固定 電路項彙總
段起始發射功率	p^0	0.825 W，即 $p^{+i/2i}$ ；式 (3.11) 每個新 served segment 的起始值。 $p^{+i/p^0=2i}$ 給每個 served segment 3 dB 的增益 預算；3 dB 是波束自身的半 功率等高線（ $F=1/2$ 恰在 $\mu=2.07123$ ，即 $\theta=\theta_3/2$ ，其 地面半徑正是 R_b ），因此 預算的大小由幾何決定而非 任選。該預算是相對於段起 始角度 $\theta_{u,s,v}(\tau_{u,s,v})$ 量的， 不是相對於波束軸：式 (3.12) 的分子是 $G^T(\theta_{u,s,v}(\tau_{u,s,v}))$ 而非 G_0 ， 所以不可行的判準是「增益 比連上那一刻掉了 3 dB」， 只有在段起始恰好落在軸心 時才等同於「離開該格」
每波束射頻輸出上限	p^{+ii}	1.65 W；式 (3.15a) 回退後 的每波束操作上限，亦為鏈 路可行性檢查的門檻。在 $V=39$ 下單顆衛星所有波束 同時滿載輻射 $39 \times 1.65 = 64.3$ W，低於 HOBS Table I 的 LEO 最大 發射功率 $P_{max}=50$ dBm $i100$ W [4]，故該上限與所 引文獻的每星功率預算相

類別	符號或關係	本研究設定
		容；本研究不另設每星上限 (見式 (3.11) 下方的排除 項)，此處僅作預算相容性 檢查
PA 最大效率與輸出回退	$\xi^{+i\bar{b}}, b_o$	0.35、5 dB；式 (3.15a)，飽 和功率 $p^s = p^{+i\bar{b}/10} = 5.218\bar{b}$ W
每啟用波束電路功率	P^c	0.338 W (300+19+14+5 mW，You 等人 Table II [26])；式 (3.16a)
衛星共用基頻功率	P^b	0.200 W [26]；式 (3.16a)

式 (3.10b) 的四項損耗中，HOBS 式 (1) 只給出名稱而未給數值；本研究以 3GPP 非地面網路報告 [17] 的對應表格代入 L_g 、 L_c 與 L_s ， L_f 則由斜距與載波頻率直接計算。此代換是本研究的建模選擇，不是 HOBS 的原始設定。 L_s 與萊斯衰落 K_R 是本模型僅有的兩個隨機項，實驗以固定亂數種子重現。

目前 active 契約不把最低速率反推、beam/satellite cap、PA 參考曲線或 min/max projection 放入 EE 主公式。這些限制若由 legacy simulator 使用，只能作為本章的執行歷史，不能反向改寫式 (3.11)–(3.17)。

本章既有數值結果若由舊版 runtime 產生，仍須以 legacy provenance 解讀；在新契約完成 runtime parity 並重新執行實驗前，不把既有結果宣稱為新版公式的實證。

Legacy 執行設定 (只作第五章 provenance)		
符號	符號	歷史設定
最低速率門檻	R^m	1 Mbit/s
PA 參考輸出功率	P_0	5.218 W；即式 (3.15a) 的 p^s 在舊 runtime 的名稱，數值 相同
大氣衰減 (legacy 式)	χ_{atm} ； $L^{atm} = 3d^{km} \chi_{atm} / (10h_s^{km})$	$\chi_{atm} = 0.05$ 。該式在天頂只給 0.015 dB，等效大氣厚度 0.3

Legacy 執行設定（只作第五章 provenance）		
符號	歷史設定	
每衛星 RF 輸出總上限	$P_{sat,max}$	km，與 20 GHz 的氣體吸收量級不符，已由表 5-2 的餘割律取代
PA 參考效率（legacy）	η_0	$10^{13/10}=19.953$ W 0.35；已由 ξ^{+ii} 取代

表 5-3：方法與評估設定

類別	符號	本研究設定
三目標純量化權重	$\Omega=(\omega_1,\omega_2,\omega_3)$	(0.5,0.3,0.2)
換手成本	(φ_1,φ_2)	同衛星換束為 0.5、跨衛星換手為 1.0
網路結構	—	主代理與鯰魚代理的每個 Q 網路均使用 100、50、50 個隱藏單元
學習與批次	B	學習率列為受控變因，掃描 {0.01,0.003,0.001}；批次大小 $B=128$
探索與目標網路	$\epsilon、K$	ϵ 由 1 線性降至 0.01，共 2000 回合；每 50 回合同步目標網路
訓練長度	$E、H$	9000 回合；每回合 10 步
主代理與鯰魚代理折扣	$\beta_M、\beta_F$	0.90、0.99
能效分層	$q_1、q_2、W$	0.50、0.80、5000 個轉移束
週期性介入	$\rho_I、[T_1,T_2]$	鯰魚樣本占 0.30；間隔由 4 至 16 步均勻抽取
競爭獎勵	η_w	1.0
目標尺度常數	(c_1,c_2,c_3)	(2471140.576,1.0,6)；由 P3

類別	符號	本研究設定
		／解析邊界得到，訓練前凍結

MODQN [2] 報告的學習率為 0.01。本研究不逕自採用任一邊的預設值，而是把學習率列為受控變因並掃描上述三個值；主結果所採用的值於實驗完成後填入。

目前凍結的尺度常數為 $(c_1, c_2, c_3) = (2471140.576, 1.0, 6)$ 。其中 c_1 是 P3 探測在 12{,}000 個已服務決策步上的 $r_{1,u}$ 第 95 百分位數， $c_2 = \phi_2 = 1.0$ 是換手成本的解析上界， $c_3 = 6$ 是 P3 探測中 $r_{3,u} \vee \hat{c}$ 第 95 百分位數的取整值。三者於訓練開始前固定，並由所有更新程序共用；原始單位下的有效取捨權重為 ω_j / c_j 。訓練後的有效貢獻或權重占比必須等訓練完成才可量測，目前尚無數值，不能由這些訓練前常數推論。

約束的作用範圍

在凍結情境下量測本節設定的三項約束是否作用。每波束射頻輸出上限 p^{+ii} 在 12{,}000 個決策步中的 **113 步(0.94%)** 上開火：該步所需的發射功率超過上限，該鏈路判為不可行，使用者於該步 unserved。

可行步的峰值鏈路功率為 1.6452 W，已用掉 3 dB 增益預算的 99.6%。**這不是「差一點超過」，是上限在削頂**：被判為不可行的那些步，所需功率的中位數為預算的 117.2%、最大值 214.8%。所需功率的分布尾端伸到上限的兩倍以上，可行步只呈現它被切斷之後的切口。

這組數字綁定於三件事： $\Delta t = 30.08$ s、暖啟動主臂，以及 stay-if-possible 參考策略。策略的影響最大：在 random-masked 參考策略下同一組設定給出 7.60%，是前者的八倍，因為它不會保住已經走進良好幾何的鏈路。 $\Delta t = 1$ s 時 outage 為 0.0000；關閉暖啟動（每個 episode 的 served segment 都由邊界重置）時在同一策略下亦為 0.0000（random-masked 下為 0.0016），可行峰值只到預算的 85.1%。

進場段齡的兩條抽樣臂都會使約束開火。主臂 $Uniform\{0, \dots, H-1\}$ 的平均進場段齡為 4.56 步，開火率 0.94%；敏感度臂 $Uniform\{0, \dots, 5\}$ 的平均為 2.54 步，開火率 0.81%。後者是量得段長 6 步所對應的平衡態年齡分布，前者與策略無關但年齡偏老。年齡相差 1.79 倍而開火率只相差 1.16 倍。此一關係是門檻型的而非線性的：平均段齡由 0 增

至 2.54 步時開火率由 0.0000 升至 0.0081，再增至 4.56 步時只多 0.0013。因此約束會開火並非由主臂的偏老年齡撐起；主臂為預註冊之主臂，其開火率視為上界。

三項幾何遮罩項在本情境下均不作用， $|A_u(t)|$ 恆為 28。遮罩與功率可行性是不同機制：前者決定使用者能選什麼，後者決定被選中的候選是否成為連線。

6. Conclusion

6.1 Summary

本研究以多目標深度 Q 學習網路 (MODQN) 作為多波束低軌衛星換手的基準，並在此架構上建立鯰魚多目標強化式學習 (MCRL)。三個目標分別對應角度感知系統能量效率、換手成本與負載平衡。MCRL 在訓練期間使用經驗塑形與獎勵塑形。完成訓練後只保留主代理，且每位使用者仍從可行候選中各自選出價值最高的動作。

6.2 Contributions

本研究的主要工作可整理如下。

在角度感知系統能量效率方面，第一個獎勵使用所選鏈路 EE 貢獻的總和， $r_{1,u}(t) = \sum_{s,v} x_{u,s,v}(t) \eta_{u,s,v}(t, \theta)$ 。偏軸角先由式 (3.7) 影響 G^T ，再在式 (3.10) 以 $H_{u,s,v}(t) G^T(\theta_{u,s,v})$ 直接進入式 (3.13) 的 wanted-link numerator；角度感知 RF power 由式 (3.11)–(3.12) 決定，同一個唯一鏈路 SINR 再決定 throughput，並透過式 (3.15)–(3.17) 形成共同系統功率與 EE。本文不再以 target SINR、需求功率反推、第二套 SINR 或概念層 cap/min/max 描述主鏈；第五章的既有數值若來自 legacy runtime，須待新契約完成 runtime parity 並重跑後才能作為新版公式的實證。

在多目標鯰魚訓練方面，主代理與鯰魚代理各包含三個 Q 網路，分別對應能量效率、換手與負載平衡；鯰魚代理的三個網路共享同一條環境軌跡與經驗池。能效分層、非對稱折扣與週期性混合批次介入改變鯰魚代理所使用的經驗與回合內回報加權。配對競爭獎勵只調整鯰魚代理的第一個目標。訓練完成後只保留主代理。

6.3 Limitations and Future Work

本文的系統功率包含功率放大器、啟用波束的射頻鏈、衛星共用的基頻功率，以及波束訓練與換手事件能量。目前設定 $E_{tr}=E_{ho}=0$ ，而其他衛星硬體、訊號處理與控制功率未納入模型。後續可擴充這些功率來源，並重新檢查其對能量效率與方法比較的影響。

目前模型以單一模擬環境為對象，能量效率定義與環境設定也包含理想化假設。MCRL與基準方法的效能差異仍待完整實驗判定；後續可在不同使用者數、星座條件與更接近實際的環境中檢查方法的適用範圍。

References

- [1] J.-H. Lee, C. Park, S. Park, and A. F. Molisch, "Handover Protocol Learning for LEO Satellite Networks: Access Delay and Collision Minimization," *IEEE Transactions on Wireless Communications*, Vol. 23, No. 7, pp. 7624-7637, Jul. 2024.
- [2] Y. Sun, Y. Zhai, W. Wu, P. Si, and F. R. Yu, "Handover for Multi-Beam LEO Satellite Networks: A Multi-Objective Reinforcement Learning Method," *IEEE Communications Letters*, Vol. 28, No. 12, pp. 2834-2838, Dec. 2024.
- [3] U. Ntabeni, B. Basutli, H. Alves, and J. Chuma, "Adaptive Handover Optimization in LEO Satellite Networks Using Energy-Aware Q-Learning," *IEEE Open Journal of the Communications Society*, Vol. 6, pp. 5657-5666, 2025.
- [4] S.-H. Chen, L.-H. Shen, K.-T. Feng, L.-L. Yang, and J.-M. Wu, "Energy-Efficient Joint Handover and Beam Switching Scheme for Multi-LEO Networks," *IEEE Vehicular Technology Conference (VTC2024-Spring)*, pp. 1-7, Singapore, 2024.
- [5] M. O. K. Mendonça, E. Lagunas, J. Grotz, A. Pérez-Neira, and S. Chatzinotas, "Deep Q-Learning-Based Handover for Spectral Coexistence Between Feeder and User Links in LEO Satellite Networks," *IEEE Open Journal of the Communications Society*, Vol. 6, pp. 6777-6791, 2025.
- [6] H. Liu, Y. Wang, P. Li, and J. Cheng, "A Multi-Agent Deep Reinforcement Learning-Based Handover Scheme for Mega-Constellation Under Dynamic Propagation Conditions," *IEEE Transactions on Wireless Communications*, Vol. 23, No. 10, pp. 13579-13596, Oct. 2024.
- [7] J. Zhu, Y. Sun, and M. Peng, "Beam Management in Low Earth Orbit Satellite Networks With Random Traffic Arrival and Time-Varying Topology," *IEEE Transactions on Vehicular Technology*, Vol. 73, No. 9, pp. 13352-13367, Sep. 2024.

- [8] M. Song, J. Tian, H. Zhang, T. Xu, H. Hu, and T. Zhou, "Deep Reinforcement Learning Based Multi-Objective Handover for LEO Satellite Networks," *IEEE Vehicular Technology Conference (VTC2025-Spring)*, pp. 1-5, Oslo, Norway, 2025.
- [9] T. Tajmayer, "Modular Multi-Objective Deep Reinforcement Learning With Decision Values," *Federated Conference on Computer Science and Information Systems (FedCSIS)*, pp. 85-93, Poznań, Poland, 2018.
- [10] T. Basaklar, S. Gumussoy, and U. Y. Ogras, "PD-MORL: Preference-Driven Multi-Objective Reinforcement Learning Algorithm," *International Conference on Learning Representations (ICLR)*, Kigali, Rwanda, 2023.
- [11] T. Schaul, J. Quan, I. Antonoglou, and D. Silver, "Prioritized Experience Replay," *International Conference on Learning Representations (ICLR)*, San Juan, Puerto Rico, 2016.
- [12] B.-H. Ke, "CDRL: Catfish-Effect-Based Deep Reinforcement Learning for Energy-Efficient Joint Switching of RF Chains and Reflecting Elements in RIS-Aided 6G Networks," M.S. thesis, Dept. Comput. Sci. Inf. Eng., National Taipei Univ., Taipei, Taiwan, 2025.
- [13] M. Calvo-Fullana, S. Paternain, L. F. O. Chamon, and A. Ribeiro, "State Augmented Constrained Reinforcement Learning: Overcoming the Limitations of Learning With Rewards," *IEEE Transactions on Automatic Control*, Vol. 69, No. 7, pp. 4275-4290, 2024.
- [14] L. Agorio, S. Van Alen, M. Calvo-Fullana, S. Paternain, and J. A. Bazerque, "Multi-Agent Assignment via State Augmented Reinforcement Learning," *Learning for Dynamics and Control Conference (L4DC), Proceedings of Machine Learning Research (PMLR)*, Vol. 242, pp. 1202-1213, Oxford, UK, 2024.
- [15] J. Holder, N. Jaques, and M. Mesbahi, "Multi-Agent Reinforcement Learning for Sequential Satellite Assignment Problems," *AAAI Conference on Artificial Intelligence (AAAI)*, pp. 26516-26524, Philadelphia, PA, USA, 2025.
- [16] Q. Ye, B. Rong, Y. Chen, M. Al-Shalash, C. Caramanis, and J. G. Andrews, "User Association for Load Balancing in Heterogeneous Cellular Networks," *IEEE Transactions on Wireless Communications*, Vol. 12, No. 6, pp. 2706-2716, Jun. 2013.
- [17] 3GPP, "Study on New Radio (NR) to Support Non-Terrestrial Networks (NTN)," 3rd Generation Partnership Project (3GPP), Technical Report TR 38.811, V15.4.0, 2020.
- [18] J. Yu and J.-H. Kim, "Analysis of SINR According to Elevation Angle in Earth Fixed Beam," *Asia-Pacific Conference on Communications (APCC)*, pp. 633-634, Jeju, South Korea, 2022.
- [19] Y. Abudurehman, J. Chu, R. Song, X. Liu, W. Huangfu, and H. Zhang, "Resource Allocation in Multibeam LEO Satellite Systems Based on Beam Hopping and Frequency Reuse," *IEEE Internet of Things Journal*, Vol. 13, No. 1, pp. 167-180, Jan. 2026.

- [20] E. Kim, I. P. Roberts, P. A. Iannucci, and J. G. Andrews, "Downlink Analysis of LEO Multi-Beam Satellite Communication in Shadowed Rician Channels," *IEEE Global Communications Conference (GLOBECOM)*, pp. 1-6, Madrid, Spain, 2021.
- [21] ITU-R, "Reference Radiation Pattern for Earth Station Antennas in the Fixed-Satellite Service for Use in Coordination and Interference Assessment in the Frequency Range From 2 to 31 GHz," International Telecommunication Union, Geneva, Switzerland, Recommendation ITU-R S.465-6, Jan. 2010.
- [22] 3GPP, "Solutions for NR to Support Non-Terrestrial Networks (NTN)," 3rd Generation Partnership Project (3GPP), Technical Report TR 38.821, V16.2.0, 2023.
- [23] S. C. Cripps, *RF Power Amplifiers for Wireless Communications*, 2nd ed. Norwood, MA, USA: Artech House, 2006.
- [24] A. Piacibello, R. Giofrè, R. Quaglia, R. Figueiredo, N. Carvalho, P. Colantonio, V. Valenta, and V. Camarchia, "A 5-W GaN Doherty Amplifier for Ka-Band Satellite Downlink With 4-GHz Bandwidth and 17-dB NPR," *IEEE Microwave and Wireless Components Letters*, Vol. 32, No. 8, pp. 964-967, Aug. 2022.
- [25] A. Morello and V. Mignone, "DVB-S2—Ready for Lift Off," *EBU Technical Review*, No. 300, Oct. 2004.
- [26] L. You, X. Qiang, K.-X. Li, C. G. Tsinos, W. Wang, X. Gao, and B. Ottersten, "Hybrid Analog/Digital Precoding for Downlink Massive MIMO LEO Satellite Communications," *IEEE Transactions on Wireless Communications*, Vol. 21, No. 8, pp. 5962-5976, Aug. 2022.
- [27] V. Mnih, K. Kavukcuoglu, D. Silver, *et al.*, "Human-Level Control Through Deep Reinforcement Learning," *Nature*, Vol. 518, No. 7540, pp. 529-533, 2015.